YAHOO!ショッピングの購入者の特徴分析基盤

研究概要:

宮澤弦氏, 佐々木潔氏, 関口優希氏が提言するデータ戦略を具現化.

EC 購買ログに対し, Wikipedia の日本時事ニュースや日本政府の家計調査等の外部環境データを動的参照し, NLP・テキストクラスタリング・時系列推移の追跡により消費者感性と購買動機変容を解明するプラットフォームを開発した.

使用データ:

・Yahoo ショッピングでのビール購入者　約 150 人の購買履歴(匿名処理済)

・総務省統計局「家計調査(e-Stat)」の所得別・用途別支出データ

・Wikipedia から抽出した「日本時事ニュースデータベース(2020-2024 年)」

目次

1. 緒言 3
2. 実務的要請に基づくシステム設計思想 3
2.1 提言 1(外部環境データ参照による消費者の多角的な理解支援) 3
2.2 提言 2(意味論的ベクトル解析による大規模購買感想の把握支援) 3
2.3 提言 3(特定購買グループの購買特徴の時系列分析支援) 3
3.「Yahoo ショッピングクロス分析ツール.py」の操作手順 4
ステップ 1： 4
ステップ 2： 4
ステップ 3： 5
ステップ 4： 5
ステップ 5： 6
ステップ 6： 6
ステップ 7： 6
ステップ 8： 7
ステップ 9： 7
ステップ 10： 7
ステップ 11： 8
ステップ 12： 9
ステップ 13： 11
ステップ 14： 12
ステップ 15： 12
ステップ 16： 13
4． 分析結果例，炭酸飲料水の購入グループの情報 14
5． 分析結果例，iPhone の購入グループの情報 16
6． 考察および今後の実運用に向けた課題 18
6.1 データ収集・統合パイプラインの自動化 18
6.2 ペルソナ構築に関する今後の方針 18
6.3 外部データソースの網羅性拡充 18
6.4 ガバナンスとプライバシー保護の強化 18
参考： 18

1. 緒言

現代のデータ分析職務およびマーケティング産業が直面する主要課題は，企業部門間に内在するデータの分断である．例えば消費者の購買ログはEC部門．マクロ経済指標に関する情報は経営部門．市場のトレンドデータ集計記録は広報部門に散在しており，このような幅広い記録を統合的に解釈・利活用する手法は長らく属人的な経験則に依存してきた．本稿で開発した「Yahooショッピングクロス分析ツール.py」はこの課題に対し，自然言語処理および外部データ参照機能を用いて解決策を提示するシステム案であり，LINEヤフー株式会社のデータ戦略を牽引する職員の実務的提言をシステム要件として具現化したプロトタイプでもある．本システムは，LINEヤフー株式会社のデータサイエンティストや企画職がAIをパートナーとし，大規模データの分析知見から得られる仮説を探求的に検証するための実務支援的・研究開発プラットフォーム案として設計したものである．

2. 実務的要請に基づくシステム設計思想

本システムのアーキテクチャは，LINEヤフー株式会社のデータ戦略部における提言を踏まえて構築された．

2.1 提言1(外部環境データ参照による消費者の多角的な理解支援)

宮澤弦氏は，AIを協働的パートナーと位置づけ，その知能的発達を通じて人間側の職務能力の成長も重要視している[1]．だが購買ログを無目的に機械学習モデルに入力させただけでは，社会現象が消費者に与える購買影響の分析結果，および購買客層の金銭事情を考慮したECサイト利用事情等をAIに検討させ，企業職員がその分析結果を利活用することは限界がある．そこで本システムでは，ECサイトの膨大な購買履歴集に対し，総務省統計局「家計調査」に基づく所得階層別支出データ，Wikipediaより抽出・構築した「時事ニュースデータベース(2020-2025年)」をシームレスに結合・参照するアーキテクチャを実装したことで，職員がECサイト利用者の利用状況・感想を多角的に分析できる機構を実装した．

2.2 提言2(意味論的ベクトル解析による大規模購買感想の把握支援)

佐々木潔氏は，AIエージェントによるYahoo！ショッピングユーザーへの高度かつ精緻な提案・支援を実現するデータ駆動型システムを強調している[2]．一方でTF-IDF等の従来の情報検索手法では同義語・類義語の識別が困難であり，消費者の潜在的意図の網羅的把握には限界が存在した．そこで本システムでは，文意解析エンジンにSentence Transformerを導入した．非構造化データであるレビューテキストを384次元の高次元密ベクトル空間に写像することで，表層的な語彙の差異に依存せず，意味的類似性に基づき，特定消費者層の購買感想の概要把握を実現した．

2.3 提言3(特定購買グループの購買特徴の時系列分析支援)

関口優希氏は，ECサービスの改善余地および成長阻害要因を特定するため，データ分析の必要性を指摘した[3]．この指摘を踏まえ本システムでは，特定購買グループの購買品・購買感想を時系列追跡する機能を実装した．購買感想において，配送プロセスや製品品質等に関する否定的語彙群の出現が，過去中長期的に統計的な増加傾向を示すことを把握可能とすることで，具体化した不満意見からユーザーストレスの削減施策の立案を支援できると考える．また特定クラスターにおける共起購買物の傾向や肯定的な購買感想の語群推移も併せて分析することで，時系列別に顧客ニーズに沿った購買推薦商品の選定や，ECサイトキャンペーン企画の実施時期の決定に寄与する．

3.「Yahooショッピングクロス分析ツール.py」の操作手順

ステップ1：

スクレイプ対象の商品画面をYahoo！ショッピングサイトから開き，URLをコピーすること(下記画像の赤枠を参考に).
今回はサッポロビール黒ラベルの48本の箱買い商品の画像を開いた(図1は48本ではなく24本の画像なので注意).

図1．スクレイプ対象商品の参考画面

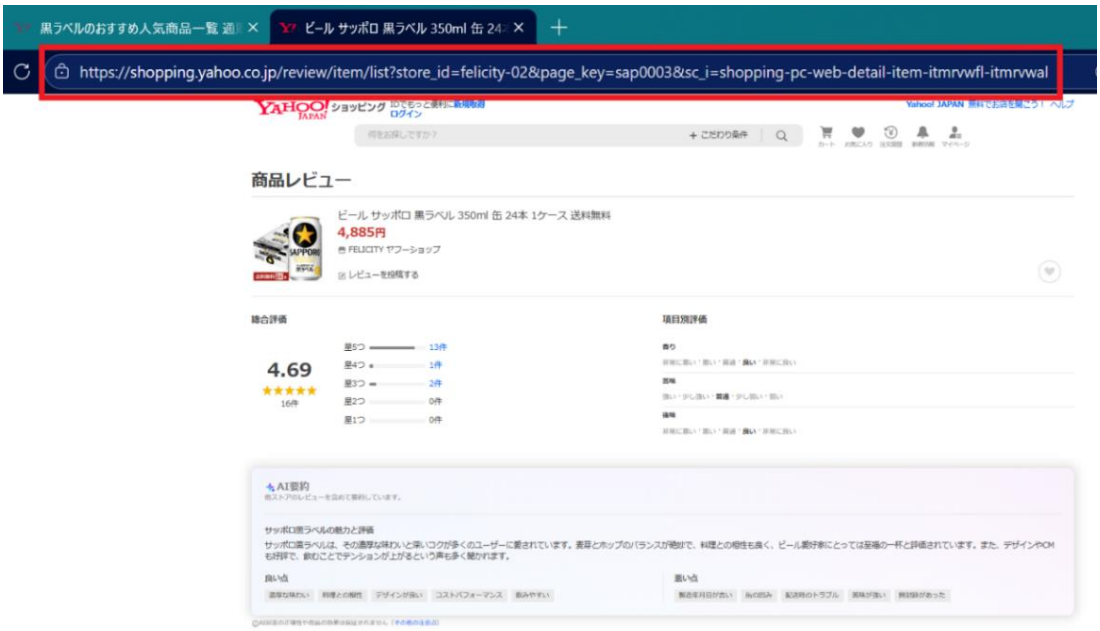

ステップ2：

スクレイピングソフト「ScrapeStorm」で図2のフローチャートを再現して起動ボタンをクリック．ステップ1で選んだ商品の全購入者一人一人の購買履歴がダウンロードできる．今回は上記48本の商品の購入者の内，約150人の購買履歴をダウンロードした(データ保存形式はExcel形式を推奨).

図2．ScrapeStormにおけるスクレイプ設定画面

補足：

データ抽出箇所は上記画像のレビュー記載箇所(青部)を選択．フローチャートのクリック箇所はページ下部の「もっと見る」を選択.

ステップ3：

Webサイト「政府統計の相談窓口」から「年間収入階級別１世帯当たり１か月間の収入と支出」というcsv資料をダウンロード[4]．今回の研究では2021年10月～2024年5月の年月別のデータをダウンロードした．

ステップ4：

Wikipediaにて「20●●年の〇〇-Wikipedia」をWebページで開き，「できごと」における1月～12月のテキストをコピー＆ペースト方式で適当なテキストデータに保存する．また同ページ末尾の「注釈」以降におけるテキストも同様に別のテキストデータとして保存する．今回の研究では，2021年～2024年の政治，経済，日本，日本競馬，相撲，プロ野球のカテゴリを保存した．なお「できごと」や「注釈」の名前が無い場合は，図3の「できごと」や図4の「注釈」に相当する箇所から参照すること．

図3．「できごと」の文章が記載されたWikipediaのページ参考画像

図4．「注釈」以降の文章が記載されたWikipediaのページ参考画像

ステップ5：

コマンドプロンプトで「改行-03-2種を統合-競馬等.py」を起動(図5参照).

図5．コマンドプロンプトにおける「改行-03-2種を統合-競馬等.py」の起動画面例.

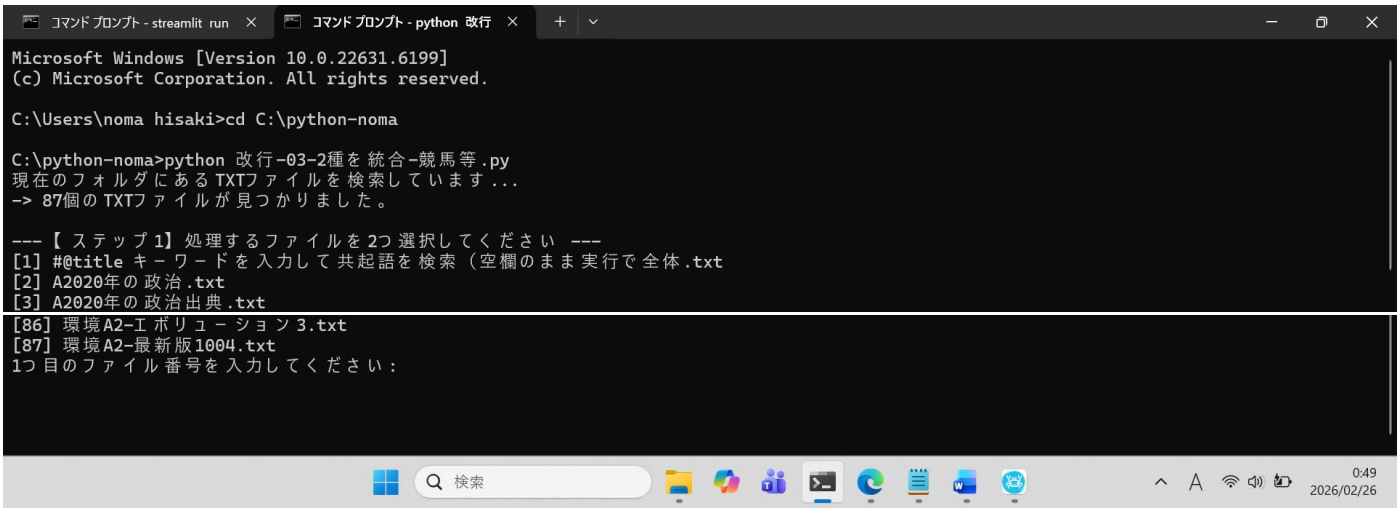

補足：

図3・図4で，2020年の政治-Wikipediaの「できごと」のテキストを「A2020年の政治.txt」としてローカルPCに保存し，2020年の政治-Wikipediaの「注釈」以降のテキストを「A2020年の政治出典.txt」としてローカルPCに保存した場合，上図のように表示される．「1つ目のファイル番号を入力してください」では「できごと」のテキストデータを選択すること．すると「【ステップ3】出力するCSVファイル名を入力してください」と表示され，CSVファイルが自動ダウンロードできるので，好きなファイル名で保存すること.

ステップ6：

コマンドプロンプトで，「Yahooショッピングクロス分析ツール.py」を起動(図6参照).

図6．コマンドプロンプトで以下の画面が表示されたら起動完了.

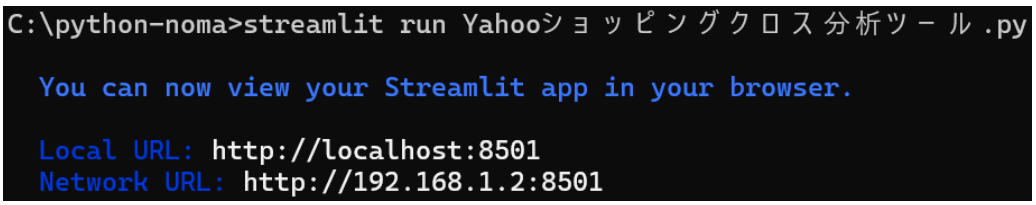

ステップ7：

起動画面のサイドバー上部に「１．Yahoo！ショッピングの購買記録をアップロード」と表示されるので，図2のScrapeStormで取得済の購買履歴CSV/Excelデータ集を一括で読み込むと，図7のような画面が表示される.

図7．実際のシステム操作画面．サイドバーにてデータアップロードとフィルタリング設定を行う．

ステップ8：

起動画面のサイドバー上部の「２．データの絞り込み条件」で，アップロード済の母集団データから解析対象としたいデータ選定としてフィルタリング設定を行う(必須ではない)．フィルタリング設定においては，データ分析期間の絞り込み，特定キーワードを含む購買商品のみ，特定キーワードを含む購買感想のみ等を分析対象に設定可能．他にもECサイトでの購買評価時の評価星(1～5)でフィルタリング．定義済辞書による購買感想の感情スコア値(怒り・悲しみ等の各感情で1～5の数値式)でフィルタリングできる．

ステップ9：

起動画面のサイドバー上部の「３．年収別の出費情報をアップロード」で，ステップ3でダウンロードしたファイルを一括アップロード．

ステップ10：

起動画面のサイドバー上部の「４．Wikipediaニュースのアップロード」で，ステップ4でダウンロードしたファイルを一括アップロード．

ステップ11：

次に「1. 購買グループ・クラスター分析」で図7を再現する．「基準を選択」はいずれの選択内容でも問題ない．

補足：

1．「類似度を測る基準列を選択」で「商品名」を選ぶと「基準を選択」の記載名に対して高類似の「商品名」が抽出できる．「コメント」を選ぶと「基準を選択」の記載名に対して高類似の「コメント」が抽出できる．なお「コメント」とはショッピングレビューテキスト(購買感想)のことを示す．
2．「クラスタリングを行う分析列を選択」では，Yahoo！ショッピングレビュー群に対し，「商品名」「コメント」のいずれかでクラスタリング対象を選ぶ機能である．
3．「類似度を測る基準列を選択」で「商品名」を選択した場合，Yahoo！ショッピングレビュー群における「商品名」が「基準を選択」にて一覧表示される為，任意で一つ選択すること．または「コメント」を選択した場合，Yahoo！ショッピングレビュー群における購買感想テキストが「基準を選択」にて一覧表示される為，任意で一つ選択すること．
4．「コサイン距離 (最低ライン)の設定」は0に近く，「コサイン類似度」は1に近いほど高類似性を示す指標．コサイン類似度＝1－コサイン距離の変換が可能であり，今回の研究では原則，コサイン類似度の閾値を0.75に設定した．つまりコサイン類似度0.75以上，コサイン距離0.25以下のテキストが抽出されるということ．
5．「クラスター数(分類グループ)の数」でクラスター数の設定に困る場合は，図7の「類似度・クラスタリング実行」の下部に位置する「最適なクラスター数の算出」を参照すること．「商品名」「コメント」のいずれかで最適なクラスター数を調査できる(図8参照)．
6．「分析手法を選択してください」では，高速分析重視時はTF-IDF，精度重視ではSentence Transformerを選択すること．図7ではTF-IDFを選択しているが，本研究では原則Sentence Transformerを選択している．
7．「クラスタリングの感度調整」において「コサイン距離」を選び，「コサイン距離 (最低ライン)の設定」の値を設定することで，「基準を選択」に対する高類似の情報のみを分析結果に出力させられる．「コサイン距離(特別版)」を選ぶと，「基準を選択」の内容に一切影響されず，「クラスタリングを行う分析列を選択」のカテゴリで，クラスタリングを実行できる．

図8．最適なクラスター数の算出画面．

ステップ12：

図7の「類似度・クラスタリング実行」のボタンを押した後，表1のような分析結果が出力される．

表1．「コサイン距離(特別版)」の選択時における分析出力結果の簡易例．実際には膨大なUser IDの情報が逐一記載される

User ID	基準の商品名	比較対象_商品名	分類グループ	グループ中身のコサイン類似度	分類グループの存在割合	商品名の共通単語TOP3	コメントの共通単語TOP3	コメント	喜び	好き	怒り	恐れ	悲しみ	評価星	購買日
kni	パンプス 痛くない 靴 レディース 歩きやすい (略)	カビ強力除去スプレー (略)	0	0.772	0.01%	カビ, 限定, オンライン	買う, カビ, スプレー	ニオイが強烈でスプレーした(略)	1	1	1	1	1	5	2024/1/14

補足：

1．「比較対象_商品名」では，「基準の商品名」以外の全商品名がそれぞれ記載されていく．
2．「分類グループの存在割合」は，全レビュー母集団に対する当該グループのレビュー比率．
3．「グループ中身のコサイン類似度」は，同一分類グループに属する購入商品名同士・コメント同士の類似度を示す．
4．「共通単語TOP3」は，当該分類グループ内のテキスト中に共通して出現回数が多かった単語上位3つを指し，商品名・コメントでそれぞれ別途出力される．
5．図7にて「コサイン距離(特別版)」ではなく「コサイン距離」の選択時は「コサイン類似度」の列が，「比較対象_商品名」と「分類グループ」の間に出現する．これは「比較対象_商品名」に対する「基準の商品名」の類似性が，0から1の間の数値で逐一算出されることを意味する．この時，図7の「基準を選択」の記載内容が表1の「基準の商品名」となる．
6．基本的に図7の「基準を選択」の記載内容が，表1の「基準の商品名」として記載される設計仕様である．
7．「分類グループ」では類似度の高いクラスタリング対象同士がまとまった，様々なグループ層の番号が表示される．表1に表示された全分類グループの中から，特定分類グループの購買記録(購買商品名・コメント)を時系列分析する際は，図9を参照すること．

図9．表1で表示された全グループの中から，特定分類グループを時系列分析する設定画面

補足：

1．「分類グループIDを選択」では，時系列追跡したい表1中の分類グループ(複数選択可)を選ぶフォーム.
2．「分析したいUser IDを選択」では，表1の任意User ID(複数選択可)に限定して時系列追跡できるフォーム.
3．「選択したユーザーの全購買記録を分析する」では，サイドバーの設定条件を無視した上で，選択済ユーザー・選択済分類グループの全時期の全購買記録を分析できる.
4．「STEP2」では，「商品名」「コメント」のいずれかを選び，上記1～2で選択したユーザー・分類グループにおいて，特定したキーワードを含むテキストだけを解析対象に絞り込める.
5．「STEP3」では，時系列解析したい時期を設定できる.
6．ステップ13にて「OUTPUT1」と「OUTPUT2」の詳細を説明する.

ステップ13：

特定分類グループにおける解析結果(図10参照)を例に，時系列解析記録の説明を行う.

図10．図9でランダムに選んだ計15人のユーザーの購買深堀記録

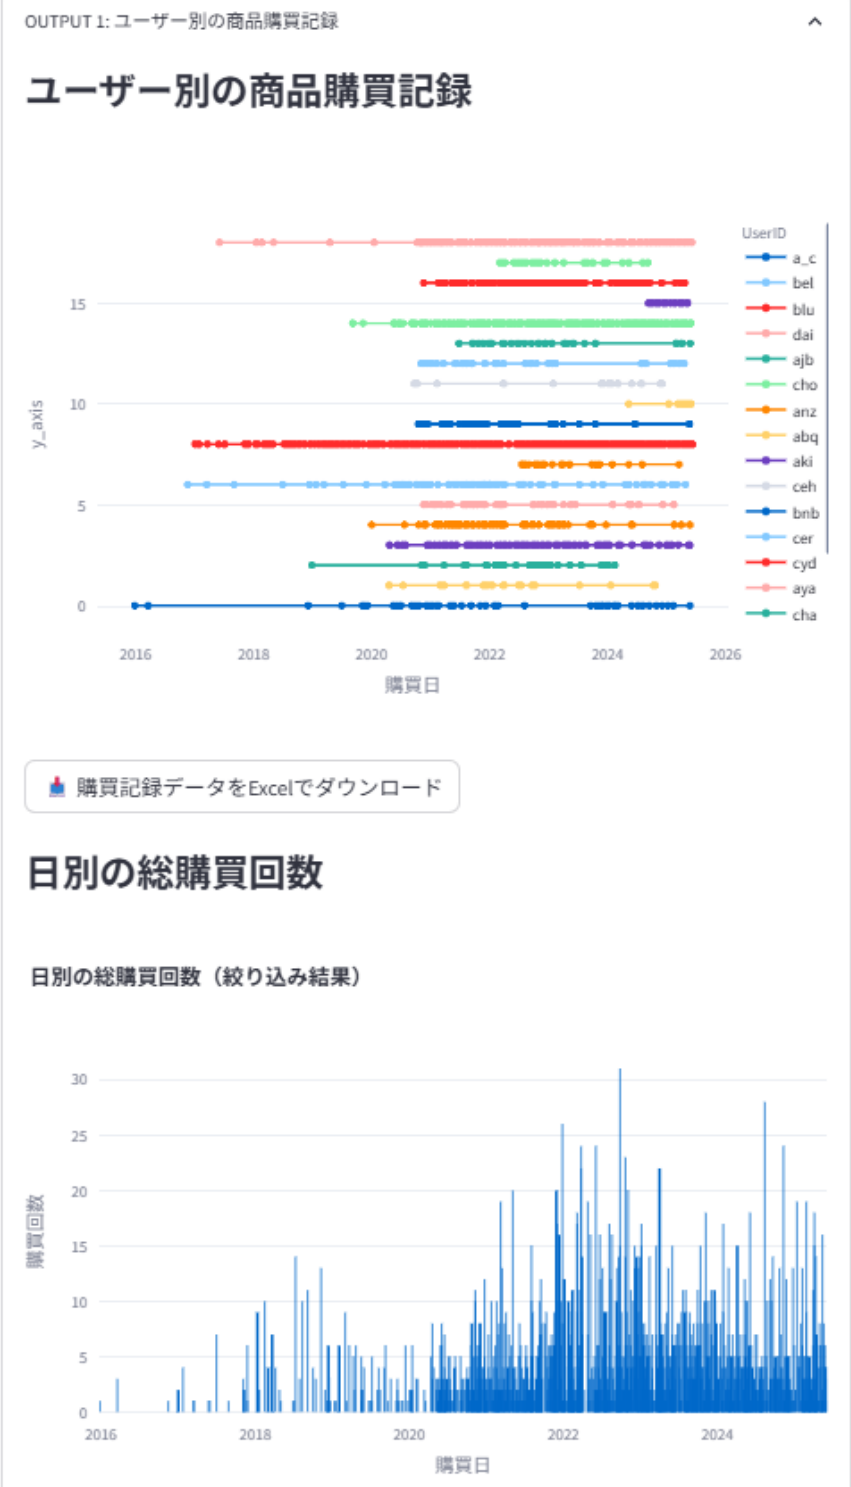

補足：

上段図では個々のユーザーの点々にカーソルを重ねることで，個々のユーザーの購買記録(購買商品・コメント・評価星・各感情スコア・購買時期)を調査可能．下段図では計15人のユーザーの購買回数がトータルで時期別に比較可能である.

ステップ 14：

「OUTPUT 1: ユーザー別の商品購買記録」の下部に「OUTPUT 2: 頻出単語解析」のタブがあり，「商品名」「コメント」のいずれかを選択・切替表示することで，図 10 の計 15 人の「商品名」「コメント」のテキストにおける頻出単語・共起単語の統計を調査できる．この時「STEP3」で統計期間を設定できる．表 2～表 5 に統計例を示す．

表 2．図 10 の計 15 人の 2023 年 7 月～8 月の購買商品名

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	送料	44	無料(44), ケース(36), ビール(35)
2	無料	44	送料(44), ケース(36), ビール(35)
3	ケース	44	ビール(38), 送料(35), 無料(35)

表 3．図 10 の計 15 人の 2023 年 7 月～8 月のコメント

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	購入	56	できる(14), なる(12), 良い(12)
2	美味しい	36	飲む(9), 購入(9), リピート(8)
3	ある	24	購入(15), 頂く(9), 飲む(7)

表 4．図 10 の計 15 人の 2024 年 7 月～8 月の購買商品名

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	送料	56	無料(56), 48(48), ビール(40)
2	無料	56	送料(56), 48(48), ビール(40)
3	48	53	ビール(42), ケース(37), 350(36)

表 5．図 10 の計 15 人の 2024 年 7 月～8 月のコメント

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	購入	89	する(24), 商品(21), ある(20)
2	ある	36	購入(21), ない(9), なる(9)
3	商品	32	購入(27), する(12), ある(11)

補足：

表 2～表 5 の「共起単語 TOP3(共起回数)」とは，順位単語と共に同テキストで使用された単語とその回数を示す．例えば 2023 年の夏季にはコメントに「美味しい」が 36 回出現し，「飲む」と 9 回，「リピート」と 8 回使用される等，味や品質への言及が見られた．2024 年の夏季では商品名に「48(本)」「ビール」「ケース」．コメントには「商品」「ある」といった無機質な語彙が増加した．両年ともに「送料」「無料」が上位を占める．これによりこのクラスターの消費者層は，当初は味を楽しんでいたものの，次第に 48 本入りのビールケースを送料無料で安く買うというコストパフォーマンス重視の購買行動へシフトしたことが定量的に示唆される．

ステップ 15：

購買データと同時期の社会時事ニュースを並列表示し，その関係性を考察するためのインターフェースを説明する．このインターフェースは「OUTPUT 2: 頻出単語解析」の下部の「Wikipedia ニュース」のタブ内に位置する．

表 6．「Wikipedia ニュース」のタブで出力される社会時事ニュースの一例

日付	情報	注釈番号	注釈情報	出典番号	出典情報
2022 年 1 月 1 日	新型(略)した[7]	[1]	公職選挙法(略)	[1]	(略)2020 年 5 月 22 日閲覧

補足：

「Wikipedia ニュース」のタブ内にて，サイドバーの「４．Wikipedia ニュースのアップロード」でアップロードした全ファイルの切替表示が可能である．Wikipedia 由来の時事ニュースの参照において，本システム上では日付・情報本文に加え，注釈番号・出典番号等の一覧を確認できる(表 6 参照)．注釈番号と出典番号が同一となる場合があるが，このような場合には情報文脈を考慮して適切な箇所を選択する必要がある．これらの機能によって，特定購買クラスターの購買感想と社会ニュースとの相関を考察し，新規施策立案への示唆を得るきっかけとなる．表 6 では 2022 年 1 月 1 日の情報列のみだが，実際は年間を通じた情報列がシステム上では表示される．一方，手作業ですべての表情報を把握するのは限界がある．そこで共起ネットワーク形式・頻出語ランキング形式で年間を通じた情報列の記載情報を素早く把握する補助機能を同時に実装した．

ステップ 16：

「2. 年収別出費分析」にて「３．年収別の出費情報をアップロード」の全ファイル資料を確認する(図 11 参照).

図 11. 「2. 年収別出費分析」の説明画面

用途分類	単位	200万円未満	200～250万円	250～300万円	300～350万円	350～400万円	400～
魚介類	円	4683	5163	5334	5519	5379	
生鮮野菜	円	4536	5453	5365	5709	5768	
菓子類	円	4300	4744	5379	5739	5745	

補足：

1．「分析対象のシートを選択」で，「二人以上の世帯」「二人以上の世帯のうち勤労者世帯」「二人以上の世帯のうち無職世帯」のいずれかを選択する.
2．「分析したい用途分類を選択してください」で，年収別の出費項目額の統計を確認できる．例えば「乳製品」「果物」「酒類」「電気代」などを選択し，年収階級別(200 万円未満～1000 万円以上)の支出額を比較できる.

4．分析結果例，炭酸飲料水の購入グループの情報

ステップ 1～2 と同様のデータ(サッポロ黒ラベル 48 本箱買い・約 150 名の購買履歴)を揃え，図 7 でコサイン類似度の閾値を 0.75 に定め，Sentence Transformer を選択し，「類似度を測る基準列を選択」で「商品名」，「クラスタリングを行う分析列を選択」で「商品名」を選択した．次に購買時期を 2024 年の 5 月・6 月に設定し，「クラスタリングの感度調整」で「コサイン距離(特別版)」を選択した為，「基準を選択」の選択内容を適当に定めた．そして「類似度・クラスタリング実行」のボタンを押した結果，分類グループの存在割合 0.05%で炭酸飲料水の購買グループ(表 7 参照)が抽出された．今回はこの炭酸飲料水の購入層の消費行動について考察する．

表 7．炭酸飲料水の購買グループの基本情報

購買時期	商品名の コサイン類似度	分類グループの 存在割合	商品名の 共通単語 TOP3	コメントの 共通単語 TOP3
2024 年 5 月・6 月	0.809	0.05%	炭酸，500，ml	おる，飲む，購入

本グループの購買記録を時系列解析した記録を下記に示す．表 8・表 9・表 14・表 15 を確認すると，2023 年および 2024 年の秋季の購入品において「冷凍」「食品」「セット」といった単語が共通しており，「送料」「無料」「セット」「食品」が上位を占める．「冷凍」は「野菜」や「ストック」という語彙と共起関係にあり，コメントにおいては「購入」「食べる」が毎年の共通傾向として上位に浮上する．

表 8．2023 年 9 月・10 月の購入品の情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	送料	24	無料(24), 48(10), ケース(9)
2	無料	24	送料(24), 48(10), ケース(9)
3	セット	18	送料(7), 無料(7), 食品(5)
4	冷凍	16	野菜(7), 食品(6), ストック(5)
5	食品	15	冷凍(16), 送料(7), 無料(7)

表 9．2023 年 9 月・10 月のコメントの情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	購入	59	さん(12), ある(11), 買う(11)
2	思う	36	購入(15), 食べる(15), ある(14)
3	食べる	32	思う(10), 美味しい(10), 購入(8)
4	ある	30	購入(9), 思う(8), 注文(7)
5	良い	29	購入(11), 買う(10), 思う(9)

これらデータは，炭酸飲料を嗜好する消費者層が，秋季において保存性の高い冷凍食品や野菜類を計画的にまとめ買いする特性を有していることを示唆している．さらに表 10・表 13 のように，二人以上の世帯における用途分類別の出費額情報(肉類、魚介類、生鮮野菜、酒類等)を所得階層別に参照することで，当該商品群の出費額の傾向を踏まえたペルソナ構築を支援する．

表 10．二人以上の世帯．2023 年 9 月の出費統計

用途分類	300～ 350 万円	450～ 500 万 円	550～ 600 万 円	650～ 700 万 円	750～ 800 万 円	900～ 1,000 万 円	1,250～ 1,500 万 円
魚介類	5903	5913	5137	5440	5364	5398	6545
肉類	5974	7717	7955	8653	8747	9072	10011
生鮮野菜	5973	5739	5470	5798	5887	5985	7305
酒類	4222	3511	4652	4605	3957	4897	4359

加えて本消費者層を軸に，ステップ 15 の補助機能が示すように，プロ野球および中央競馬に関する年間時事ニュースの頻出語記録を参照することで，プロ野球報道や競馬報道を趣味とする人間の関心対象の具体的把握と(表 11・表 12・表 16・表 17 参照)，それら関心対象に意識をしつつも炭酸飲料・野菜・肉を購買するようなペルソナの仮想構築を支援する．例えばプロ野球観戦や競馬の秋季レース観戦の同伴飲料として，炭酸水が 500ml ボトルやケース単位で大量に消費・ストックする消費者群を想起できる．

表 11．2023 年のプロ野球-Wikipedia ニュース

順位	単語	出現回数	3 単語 共起 順位	3 単語 組み合わせ	共起回数
1	発表	222	1	契約, 発表, 選手	45
			5	ジャイアンツ, 発表, 読売	39
			9	ハムファイターズ, 北海道, 発表	33
2	史上	182	1	史上, 記録, 通算	50
			4	NPB, 史上, 記録	40
			9	ソフトバンクホークス, 史上, 福岡	33
3	選手	163	1	契約, 発表, 選手	45
			2	発表, 育成, 選手	45
			9	ジャイアンツ, 発表, 選手	32

表 12．2023 年の日本競馬-Wikipedia ニュース

順位	単語	出現回数	3 単語 共起 順位	3 単語 組み合わせ	共起回数
1	競馬	228	1	ダート, 競走, 競馬	48
			3	JRA, 競走, 競馬	42
			7	勝利, 競走, 競馬	32
3	JRA	80	2	JRA, 競馬, 騎乗	33
			4	JRA, 栗東, 競馬	25
			6	JRA, 史上, 競走	22

表 13．2 人以上の世帯．2024 年 10 月の出費統計

用途分類	300～350 万円	450～500 万円	550～600 万円	650～700 万円	750～800 万円	900～1,000 万円	1,250～1,500 万円
魚介類	6346	6171	4934	5429	5449	5712	5722
肉類	6629	7532	7741	8563	8710	8793	10790
生鮮野菜	6819	6252	5729	6103	6259	6853	7602
酒類	3182	4040	3342	4138	3555	3701	4376

表 14．2024 年 9 月・10 月の購入品の情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	送料	49	無料(44), ケース(17), 24(16)
2	無料	45	送料(49), ケース(17), 24(16)
3	500	27	送料(17), 無料(15), ポイント(13)
4	セット	27	500(7), BBQ(5), 牛肉(5)
5	食品	22	送料(13), 冷凍(13), セット(12)

表 15．2024 年 9 月・10 月のコメントの情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	購入	116	会社(32), リピート(31), いただく(30)
2	リピート	40	購入(58), いただく(30), 好評(27)
3	食べる	38	良い(15), 注文(13), 白米(12)
4	いただく	38	購入(57), リピート(29), 会社(28)
5	なる	33	注文(18), 届く(15), 食べる(15)

表 16．2024 年のプロ野球-Wikipedia ニュース

順位	単語	出現回数	3 単語 共起 順位	3 単語 組み合わせ	共起回数
1	発表	352	1	こと, 発表, 選手	77
			2	発表, 育成, 選手	69
			8	ソフトバンクホークス, 発表, 福岡	61
2	選手	232	1	こと, 発表, 選手	77
			2	発表, 育成, 選手	69
			3	発表, 背番号, 選手	65
4	史上	186	1	史上, 回戦, 記録	50
			3	NPB, 史上, 回戦	44
			4	史上, 埼玉, 西武ライオンズ	43

表 17．2024 年の日本競馬-Wikipedia ニュース

順位	単語	出現回数	3 単語 共起 順位	3 単語 組み合わせ	共起回数
1	競馬	266	1	JRA, 競走, 競馬	45
			2	競走, 競馬, 騎乗	42
			6	JRA, 栗東, 競馬	33
2	競走	152	4	ダート, 競走, 競馬	33
			5	勝利, 競走, 競馬	33
			6	史上, 競走, 競馬	30

5．分析結果例，iPhone の購入グループの情報

「4．分析結果例，炭酸飲料水の購入グループの情報」と同じ条件(購買時期のみ 2023 年 1 月･2 月に変更)で分析を実行した結果，コサイン類似度 0.786，分類グループ存在割合 0.04%で定義された iPhone 購買層(表 18 参照)を発見した．

表 18．iPhone の購入グループの情報

購買時期	商品名の コサイン類似度	分類グループの 存在割合	商品名の 共通単語 TOP3	コメントの 共通単語 TOP3
2023 年 1 月･2 月	0.786	0.04%	iPhone，ケース，13	商品，購入，そう

当該グループの購買記録および関連するテキストデータ(表 19～表 26)を時系列解析すると，通年ベースで「iPhone」「ケース」「13」「15」「16」といったデバイス関連の単語やバージョン数値等が上位を占有していた．一方で通信機器とは直接的な関連性が認められない単語も観測されている．具体例には，2023 年夏季の購買品データにおいては「セット」という単語が「餃子」と顕著に共起し，続く 2024 年春季のデータにおいては「コーヒー」「ラーメン」「ショーツ」等が「セット」と強い共起性が確認された．同期間の消費者コメント内では「マスク」という単語が高い頻度で出現している．これらの記録から年間を通じて最新 iPhone 機種を EC サイトで確認する消費者群は，コーヒー･ラーメン･餃子･マスク等を不定期的に購買する可能性が存在すると，ペルソナ構築時の判断材料となりえる．

表 19．2023 年 3 月･4 月の購入品の情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	iPhone	23	13(13), ケース(11), 12(8)
2	ケース	19	iPhone(12), 13(9), 送料(6)
3	送料	17	無料(17), iPhone(6), ケース(6)
4	無料	17	送料(17), iPhone(6), ケース(6)
5	13	13	iPhone(21), ケース(10), 12(8)

表 20. 2023 年 3 月・4 月のコメントの情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	購入	52	できる(20), 商品(17), 飲む(12)
2	商品	25	購入(19), できる(10), なる(7)
3	できる	21	購入(30), 商品(13), 飲む(8)
4	なる	16	購入(11), 商品(11), 思う(7)
5	思う	15	購入(15), なる(7), 商品(7)

表 21. 2023 年 7 月・8 月の購入品の情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	ケース	22	送料(10), 無料(10), 世代(10)
2	送料	19	無料(19), ケース(11), ml(9)
3	無料	19	送料(19), ケース(11), ml(9)
4	ml	16	ケース(9), 送料(9), 無料(9)
5	セット	16	餃子(9), ml(8), iPhone(5)

表 22. 2023 年 7 月・8 月のコメントの情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	購入	49	する(17), 商品(16), 思う(15)
2	商品	26	購入(24), する(9), 思う(8)
3	する	22	購入(17), 思う(11), 商品(10)
4	思う	22	購入(12), する(10), 商品(8)
5	いる	18	購入(14), 飲む(13), する(7)

表 23. 2024 年 3 月・4 月の購入品の情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	ケース	17	世代(8), iPhone(5), 48(5)
2	送料	13	無料(13), マスク(7), 48(5)
3	無料	13	送料(13), マスク(7), 48(5)
4	iPhone	11	ケース(8), 13(5), SE(4)
5	セット	9	コーヒー(4), ラーメン(3), ショーツ(3)

表 24. 2024 年 3 月・4 月のコメントの情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	購入	34	できる(11), いる(10), 商品(10)
2	商品	23	マスク(12), 購入(10), ある(7)
3	いる	16	マスク(14), 商品(12), 購入(8)
4	思う	16	マスク(14), いる(6), 着ける(6)
5	ある	15	マスク(12), 商品(10), 食べる(6)

表 25. 2024 年 7 月・8 月の購入品の情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	送料	17	無料(15), ml(7), ケース(7)
2	16	17	iPhone(15), 15(12), Plus(5)
3	iPhone	16	16(17), 15(12), Plus(5)
4	無料	15	送料(15), ml(7), ケース(7)
5	ケース	15	ml(7), 送料(7), 無料(7)

表 26. 2024 年 7 月・8 月のコメントの情報

順位	単語	出現回数	共起単語 TOP3 (共起回数)
1	購入	36	商品(20), 思う(11), できる(10)
2	商品	28	購入(17), 届く(9), できる(8)
3	ある	21	購入(8), 思う(7), 商品(6)
4	思う	19	購入(12), ある(6), 商品(5)
5	届く	16	購入(12), 商品(11), ある(6)

6. 考察および今後の実運用に向けた課題

本研究では，EC 購買ログに家計調査や Wikipedia ニュース等の外部環境データを動的に結合し，自然言語処理と外部データ参照機能を用いることで，消費者の潜在的な購買動機変容を考察するプロトタイプシステムを開発した．分析の結果，炭酸飲料と冷凍食品の併売傾向の発見や，特定ニュース(プロ野球・競馬等)と消費行動の定性的相関の考察機会の提供など，ペルソナ構想に繋がる支援術を新たに開発できた．一方で本システムを企業の実際のマーケティング・分析基盤としてスケールさせるためには，以下の工学的およびビジネス的課題を解決していく必要がある．

6.1 データ収集・統合パイプラインの自動化

本プロトタイプでは、外部環境データ(Wikipedia のできごと等)の抽出や，スクレイピングツールを用いたレビュー取得において，一部手作業(GUI 操作やコピー＆ペースト)によるデータ成形プロセスが介在している．今後は本番環境へのデプロイを見据え，各種 API を活用したクローラーの開発，定期バッチ処理によるベクトルデータベースへの自動格納など，新たなパイプラインの構築が必要である．

6.2 ペルソナ構築に関する今後の方針

本システムにより，iPhone 購入層におけるコーヒーやラーメンへの不定期な需要といった特異な併売仮説を導出できた．次のステップとしては，本基盤で抽出されたペルソナに対して効果的なレコメンド施策(A/B テスト)を検討し，商品クリック率や購買転換率の向上を定量的に検証するフェーズへの移行が求められる．

6.3 外部データソースの網羅性拡充

上記のような，日用品や嗜好品に対する偶発的な需要変動や特定の併売背景要因を特定する試みにおいて，現行の分析システムの限界が露呈している．現状のソフトウェアに実装されている Wikipedia ニュース連携機能は，スポーツ・政治経済といった特定分野の時事ニュースの参照には有効だが，医療衛生トレンドの変遷や食文化の局所的な動向は網羅的に捕捉できていない．購買行動に突発的な影響を及ぼす潜在的なマクロ要因をより高精度に分析するためには，テキストマイニングの対象となるニュース情報源を、公衆衛生や消費財市場全体にまで拡張する改修が不可欠である．

6.4 ガバナンスとプライバシー保護の強化

本実証実験では匿名処理済みの購買記録を使用したが，実運用において個人購買データと外部データを統合解析する際，データガバナンスの徹底が不可欠となる．特徴量ベクトルの不可逆化処理や，部門間のアクセス権限の厳密な制御機構をシステム要件として組み込むことが今後の課題である．

参考：

[1] “「AI をパートナーとして共に成長する」生成 AI 役員．宮澤が描く未来”，入手先<https://www.lycorp.co.jp/ja/story/20250714/ai_rule.html>．(参照:2026-02-05)

[2] “「データの力で進化する」CDO 佐々木潔が語る生成 AI 時代のデータ戦略とガバナンス？”．入手先<https://www.lycorp.co.jp/ja/story/20250814/cdo.html>．(参照:2026-02-05)

[3] “データサイエンティストが語る、データ分析をサービス改善と会社の成長につなげる醍醐味とは”．入手先<https://note.com/lycorp_recruit/n/ncab59904366f>．(参照：2026-02-05)

[4] “家計調査 / 家計収支編 二人以上の世帯 詳細結果表”．入手先<https://www.e-stat.go.jp/stat-search/files?page=1&layout=datalist&toukei=00200561&tstat=000000330001&cycle=1&year=20250&month=12040604&tclass1=000000330001&tclass2=000000330004&tclass3=000000330005&stat_infid=000040281588&result_back=1&tclass4val=0>．(参照:2026-02-05)(本記録:2025 年 4 月)